


Datenanalyse in Python:

Airbnb-Preise in Europäischen Städten

Autor: Nataliia Melnytska

Kurs: DataSmart Point

Datum: December 2025



Projektziel & Überblick



Es handelt sich um eine Datenanalyse zu den Airbnb-Preisen in 10 europäischen Städten:



- Ziel: Datenbasierte Insights zu Airbnb-Preisen



- Fokus: Preisstrukturen, Nachfrage, Optimierungsmöglichkeiten



- Nutzen: Einfluss räumlicher Faktoren auf den Preis - strategische Entscheidungen, Preisgestaltung



Problemformulierung




- Zentrale Frage: Wie variieren Airbnb-Preise in europäischen Städten?



- Schlüsselfeatures: Preis, Stadt, Wochenzeit, Unterkunftstyp / "Superhost", Bewertungen ('cleanliness_rating', 'guest_satisfaction_rating')



- Relevanz: Preisoptimierung, Marketingstrategien, Kundenzufriedenheit



Datenerhebung

Datenquelle: <https://www.kaggle.com/datasets/thedevastator/airbnb-prices-in-european-cities>

- ⌕ 20 separate CSV-Dateien, die einzelne Angaben für 10 Städte, „weekdays“ und „weekends“ enthalten.
- ⌕ Die 20 separaten CSV-Dateien wurden zu einem gemeinsamen DataFrame zusammengefasst.

```
1 staedte = ['amsterdam', 'athens', 'barcelona', 'berlin', 'budapest', 'lisbon', 'london', 'paris', 'rome', 'vienna']
2 zeiten = ['weekdays', 'weekends']
3
4 dataframes = []
5
6 for stadt in staedte:
7     for zeit in zeiten:
8         datei_name = stadt + '_' + zeit + '.csv'
9         #print(datei_name)
10        df1 = pd.read_csv(datei_name)
11        df1['stadt'] = stadt
12        df1['zeit'] = zeit
13        dataframes.append(df1)
14
15 df = pd.concat(dataframes, ignore_index=True)
```

```
1 df.to_csv('airbnb_full.csv')
```

der zusammengefasste DataFrame wurde als separate Datei airbnb_full.csv gespeichert.

Ergebnis: **51.707 Zeilen x 23 Spalten**

Erstprüfung der Daten

Der DataFrame zeigt folgende Eigenschaften auf:

- Wir sehen, dass es im DataFrame keine non-Null-Werte gibt.
- Der DataFrame enthält die Datentypen **int64**, **float64**, **object** und **boolean**.
- attr_index**, **attr_index_norm**, **rest_index** und **rest_index_norm** sind in keiner der Begleitdokumentationen zum Datensatz spezifiziert. Die Bedeutung dieser Merkmale bleibt unklar, daher werden sie in der Analyse nicht verwendet.
- Max ,**'total_room_price'** - 18545.45
- Min ,**'total_room_price'** - 34.78



```
1 df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 51707 entries, 0 to 51706
Data columns (total 23 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Unnamed: 0.1                          51707 non-null  int64
1   Unnamed: 0                             51707 non-null  int64
2   realSum                                51707 non-null  float64
3   room_type                              51707 non-null  object
4   room_shared                            51707 non-null  bool
5   room_private                           51707 non-null  bool
6   person_capacity                        51707 non-null  float64
7   host_is_superhost                      51707 non-null  bool
8   multi                                  51707 non-null  int64
9   biz                                    51707 non-null  int64
10  cleanliness_rating                     51707 non-null  float64
11  guest_satisfaction_overall              51707 non-null  float64
12  bedrooms                                51707 non-null  int64
13  dist                                    51707 non-null  float64
14  metro_dist                              51707 non-null  float64
15  attr_index                              51707 non-null  float64
16  attr_index_norm                         51707 non-null  float64
17  rest_index                              51707 non-null  float64
18  rest_index_norm                         51707 non-null  float64
19  lng                                      51707 non-null  float64
...
21  stadt                                   51707 non-null  object
22  teit                                    51707 non-null  object
dtypes: bool(3), float64(12), int64(5), object(3)
```

Datenbereinigung

Motto: "Garbage In, Garbage Out" – Qualität vor Quantität.





Durchgeführte Schritte:

- ⌚ Duplikaten entfernen, Methode - drop_duplicates – **keinen Duplikaten**
- ⌚ Überprüfung der Spalten auf fehlerhafte Daten – **keine fehlerhaften Daten**
- ⌚ Spalte umbenennen
- ⌚ Variablentypen prüfen und konvertieren: numerische Formate und 'string' Formate
- ⌚ Verschiedene Gruppieren und Auswertungen durchführen
- ⌚ Spalten löschen, zB 'Unnamed: 0.1', 'Unnamed: 0', 'attr_index', 'attr_index_norm', 'rest_index' und 'rest_index_norm'
- ⌚ Feature Engineering: Erstellung neuer Metriken wie price_per_person und auf Position 0 zu verschieben


Marktanalyse: Angebot nach Städten

Geografische Verteilung der
Bestellungen:

- ⌕ Dominanz: London, Rom und Paris stellen das größte Angebot.
- ⌕ Nischen: Amsterdam und Berlin haben weniger, aber oft hochpreisige Angebote.
- ⌕ Insight: In Top-Städten ist die Konkurrenz massiv; Differenzierung ist hier überlebenswichtig.




Einfluss der Zeit (Wochentag vs. Wochenende)




- ⌚ Preise steigen an Wochenenden signifikant an.
- ⌚ Dynamisches Pricing ist kein "Bonus", sondern Pflicht für Hosts, um Erträge zu maximieren.

Einfluss der Wochenzeit an Buchungszahlen und Preis




⌚ In fast allen Städten liegen die Buchungszahlen am Wochenende über denen an Wochentagen, was auf intensiveren Freizeit- und Kurzreisetourismus hindeutet.



⌚ Wochenenden sind in fast allen Städten teurer, was auf eine hohe Nachfrage an diesen Tagen hindeutet.

Preisanalyse & Ausreißer



⌚ **Max** , 'total_room_price' - **18545.45**



⌚ **Min** , 'total_room_price' - **34.78**

⌚ Die Mehrheit der Airbnb-Angebote befindet sich im niedrigen bis mittleren Segment

⌚ Die lange, flache Verteilung ("Long Tail") weist auf seltene, sehr teure Luxus-Ausreißer hin

Preisanalyse & Ausreißer


Preisverteilung nach Stadt (Vergleich)



- ⌚ Top-Preise: Amsterdam und Paris führen im Durchschnitt.
- ⌚ Budget: Athen und Budapest bieten die günstigsten Optionen.



- ⌚ Segmentierung: Extreme Ausreißer (>500) verzerren den Durchschnitt.
- ⌚ -> Strategische Trennung in Analyse von Massenmarkt und Luxussegment.

Trennung in Analyse von Massenmarkt und Luxussegment





- ⌚ 74,4 % entfallen auf Standardangebote – Dominanz des erschwinglichen Marktsegments.
- ⌚ 25,6 % entfallen auf Luxusangebote – dies macht sie zu einem Nischenbereich , in dem aber viel Potenzial für Premium-Dienstleistungen liegt.

Analyse von Host-Type




- ⌚ ein ‚Superhost‘ ist der bestbewertete und erfahrenste Gastgeber im Airbnb-Ranking
- ⌚ Die meisten Angebote werden von normalen Gastgebern platziert, jedoch nehmen Superhosts einen bedeutenden Marktanteil ein.
- ⌚ Rom und Athen scheinen die höchste Anzahl an Superhosts zu haben, während ihr Anteil in Paris und London relativ gering ist.
- ⌚ Das Zeichen „Superhost“ schafft Vertrauen beim Kunden.

Verteilung der Zimmerarten und Personenkapazität



- 📍 Der Airbnb-Markt richtet sich hauptsächlich an Paare und kleine Gruppen, die vollständig separate Apartments mit durchschnittlicher Kapazität bevorzugen.

Korrelation Sauberkeit vs. Gästezufriedenheit



⌕ Sauberkeit & Zufriedenheit: Starke positive Korrelation (~ 0.71)

⌕ Je höher die Sauberkeit, desto höher die Zufriedenheit

Korrelation Preis vs. Gästezufriedenheit



- Ⓐ Der Preis ist nicht der einzige Faktor für Komfort, da bei gleicher Zufriedenheit eine große Preisspanne besteht.

Handlungsempfehlungen

⌚ Die Qualität (Sauberkeit) und die Lage (Entfernung zum Zentrum/zur U-Bahn) beeinflussen die Zufriedenheit stärker als der Preis.

⌚ In Top-Städten ist die Konkurrenz massiv -> Differenzierung ist hier überlebenswichtig

⌚ Dynamisches Pricing ist kein "Bonus", sondern Pflicht für Hosts, um Erträge zu maximieren.

⌚ Luxusangebote – ein Segment mit großem Potenzial für Premium-Dienstleistungen.

Für Hosts:

- ⌚ Sauberkeit ist der größte Hebel für 5-Sterne-Bewertungen.
- ⌚ Superhost-Status korreliert mit höheren Buchungszahlen.

Für Plattform/Investoren:

- ⌚ Fokus auf Amsterdam für Hochpreis-Segment.
- ⌚ London/Rom für Volumen-Strategie.


Korrelations-Heatmap der wichtigsten Variablen



Sind die Gäste zufrieden?



Ja!



Fragen & Diskussion

Danke für Ihre Aufmerksamkeit

Besonderer Dank dem **DataSmart Point-Team**

```
1 from __future__ import braces
Cell In[56], line 1
  from __future__ import braces
SyntaxError: not a chance
```



Zusätzlich: Verteilung der Personenkapazität - Treemap

